

广告数仓项目总结

一、项目背景与目标

在本次尚硅谷大数据项目之广告数仓的构建过程中，我们深入扮演了一家小型电商企业的角色，面对复杂多变的广告市场，作为广告主向今日头条、抖音等多个广告媒体投放广告。项目的主要目标是精准统计和分析各广告平台的曝光和点击行为，有效识别异常流量，从而科学监测广告投放效果，优化广告策略。具体统计指标不仅涵盖各省市、各广告平台、各操作系统以及各广告在每个小时的点击次数和曝光次数，还要求能够深入区分正常流量和异常流量，为业务决策提供坚实的数据支撑。

二、主要工作内容

1. 业务调研与需求分析

业务调研：

深入广告业务的核心流程，细致了解广告的曝光、点击以及后续转化等关键环节。与业务团队紧密沟通，明确广告投放的策略、目标受众及预期效果。

需求分析：

根据业务需求，细化统计指标，确保数据能够全面反映广告投放效果。

确定关键维度，如广告名称、日期、省市、平台、操作系统等，为数据分析提供多维度视角。

2. 数据仓库设计与建模

维度模型设计：

精心设计事实表（如广告事件事实表），确保能够完整记录广告曝光和点击等业务过程。

构建维度表（如广告信息维度表、平台信息维度表），详细描述业务过程的环境，为数据分析提供丰富背景信息。

分层设计：

数据仓库划分为 ODS（操作数据存储层）、DIM（维度层）、DWD（明细数据层）等多层，每层承担不同的数据处理任务，确保数据流动有序、处理高效。

引入汇总层（DWS）和应用层（ADS），以满足不同层次的数据分析需求。

3. 数据采集与预处理

数据采集：

利用 Flume 和 Kafka 实时采集广告曝光和点击的日志数据，确保数据及时、准确。

通过 DataX 工具定期同步广告管理平台数据库中的维度数据，保证维度信息的更新和一致性。

数据预处理：

对原始日志数据进行清洗和解析，提取关键字段，如事件时间、事件类型、广告 ID、平台、IP、User Agent 等。

自定义函数解析 IP 地址和 User Agent，获取精确的地理位置、浏览器类型、操作系统版本等信息，为流量识别和分析提供基础。

4. 数据装载与存储

ODS 层数据装载：将清洗后的原始数据加载到 ODS 层的各表中，为后续处理提供数据源。

DIM 层数据装载：对维度数据进行整合和标准化处理，加载到 DIM 层，确保维度信息的统一和规范。

DWD 层数据装载：对事实数据进行深入处理，包括异常流量识别、数据关联等复杂操作，加载到 DWD 层，为数据分析提供高质量的数据集。

5. 数据分析与报表导出

Clickhouse 数据导出：鉴于 Clickhouse 在处理大规模数据查询方面的优势，我们选择使用 Spark SQL 查询 Hive 中的数据，并通过 JDBC 高效写入 Clickhouse。这一步骤确保了数据分析的低延迟和高效率。

报表制作：利用 FineBI 等强大的报表工具，制作交互式、可视化的报表。报表不仅满足业务部门的日常分析需求，还支持下钻、筛选等高级功能，为业务决策提供直观的数据支持。

6. 任务调度与自动化

DolphinScheduler 调度：配置复杂的工作流，实现数据采集、预处理、装载、分析等任务的自动化调度。通过设置定时任务和依赖关系，确保各环节紧密衔接、高效运行。

监控与告警：集成监控和告警机制，实时监控任务执行情况，一旦发现异常立即触发告警通知相关人员及时处理。

7. 性能优化与安全保障

性能优化：针对数据量大、查询复杂的特点，对数据库、数据仓库进行性能调优。通过索引优化、分区策略等手段提高查询效率。

安全保障：加强数据安全管控，确保数据在采集、存储、处理过程中的安全性。通过权限控制、数据加密等措施防止数据泄露和非法访问。

